

lab2

Условие

Данная лабораторная работа будет представлять собой соревнование на Kaggle.

Примечание: датасет — тот же, что и был на задаче регрессии, изменилась только целевая переменная, поэтому вы можете оставить тот же пайплайн обработки данных для тренировочной выборки.

В рамках этого соревнования вам предстоит обучить модель на основе датасета из «train_c.csv», содержащего около 10,000 строк. Предсказываемой переменной является «**LoanApproved**». После обучения вы сможете проверить эффективность вашего алгоритма на тестовом наборе данных из «test_c.csv», а затем отправить в тестирующую систему. Более подробную информацию по данным и посылкам решений можно найти на странице соревнования.

В данной работе разрешено использование любых моделей *классического* машинного обучения.

Оценивание

Разбалловка

Работа оценивается в 20 баллов и складывается из двух компонент:

15р. *Обязательные задания по коду.*

5р. *Защита лабораторной работы.*

Задания по коду

Список обязательных заданий по коду (15 баллов) и их оценивание в баллах:

- 1р.** *Провести разведочный анализ данных (EDA): построить графики зависимости некоторых признаков друг от друга, график целевой переменной и матрицу корреляций, сделать выводы. Подготовить на основе выводов данные для обучения.*
- 3р.** *Реализовать класс бэггинга, который для обучения методом `fit` обучает n базовых моделей b . Сравнить полученные после обучения результаты с реализацией из `sklearn`.*
- 5р.** *Реализовать класс градиентного бустинга, который для обучения методом `fit` обучает n базовых моделей b . Сравнить полученные после обучения результаты с реализацией из `sklearn` и других библиотек.*
- 1р.** *Сравнить результаты работы алгоритмов градиентного бустинга: реализация из `sklearn`, `LightGBM`, `XGBoost`, `CatBoost`. Выбрать алгоритм с лучшей метрикой на данных.*

- 2р. Подобрать оптимальные гиперпараметры для лучшей модели с помощью Optuna.
- 0.5р. Реализовать метрику Accuracy, протестировать и сравнить полученный результат с Accuracy из sklearn.
- 0.5р. Реализовать Precision, протестировать и сравнить с метрикой из sklearn.
- 0.5р. Реализовать Recall, протестировать и сравнить с метрикой из sklearn.
- 0.5р. Реализовать F1-score, протестировать и сравнить с метрикой из sklearn.

Дополнительные 2 балла можно получить за реализацию метрик AUC-ROC и AUC-PR и последующее сравнение с готовыми реализациями.

Основная метрика

Для получения баллов за код и последующего допуска к защите необходимо получить приемлемое значение основной метрики задачи.

В качестве основной метрики используется **ROC-AUC** (Area Under the Receiver Operating Characteristic Curve). Метрика вычисляет площадь под кривой ROC, которая отражает зависимость между True Positive Rate (TPR) и False Positive Rate (FPR) при различных порогах классификации.

Минимальное пороговое значение ROC-AUC, которое можно получить при предсказаниях на публичной тестовой выборке и при котором можно допустить к защите работы составляет 0.75.

Важно отметить, что хотя ROC-AUC является основной метрикой для оценки качества модели и окончательный скор будет вестись только по ROC-AUC, вы должны использовать и другие метрики для самопроверки, такие как Precision, Recall, F1-score, PR-AUC.

Загрузка ноутбука

После получения приемлемой метрики ($\text{ROC-AUC} > 0.75$) после отправки на Kaggle, необходимо загрузить ваш ноутбук («.ipynb»-файл) на свой GitHub для оценивания заданий по коду, а также для проверки на оригинальность. Затем нужно оставить комментарий в Google-таблице с оценками в столбце «lab2» в строке со своей фамилией о том, что вы выполнили работу с указанием ника на Kaggle.

Защита работы

После оценки заданий по коду, вы должны защитить лабораторную работу. За защиту можно получить до 5 баллов. На самой защите необходимо кратко рассказать про своё решение, а также ответить на вопросы по теории, связанные с логистической регрессией, метриками классификации, решающих деревьев, ансамблями (бэггинг и бустинг) и подбором гиперпараметров.

Оценку за задания по коду можно повышать до дедлайна, оценку за защиту поднять нельзя.